

OTIMIZAÇÃO DE PROCESSOS JURÍDICOS UTILIZANDO AUTOMAÇÃO E INTELIGÊNCIA ARTIFICIAL

OPTIMIZATION OF LEGAL PROCESSES USING AUTOMATION AND ARTIFICIAL INTELLIGENCE

GUSTAVO HENRIQUE DA CUNHA CALANZANI

Graduando em Ciência da Computação

ghc.calanzani@gmail.com

JULIA DA COSTA MACHADO

Graduanda em Ciência da Computação

juumachado@hotmail.com

HOWARD CRUZ ROATTI

Prof.º Msc. Centro Universitário FAESA

howard.cruz@faesa.br

RESUMO

O presente trabalho propõe uma solução tecnológica para a otimização de processos jurídicos por meio da integração de Automação Robótica de Processos (*Robotic Process Automation*, RPA) e Inteligência Artificial (IA). A proposta visa resolver a morosidade e a ineficiência do sistema judiciário brasileiro, especialmente no que tange à classificação de documentos jurídicos. A metodologia consistiu na extração de textos de documentos públicos, aplicação de métricas estatísticas para avaliar a importância de uma palavra em documentos individuais e em coleções de documentos, treinamento de um modelo de aprendizado de máquina utilizando o

algoritmo *Naive Bayes* e geração de uma interface *web* para controle da automação. O modelo treinado, juntamente com o vetorizador, foi exportado com o uso da biblioteca *pickle*, permitindo sua reutilização em sistemas automatizados. Os testes demonstraram alta eficácia do sistema, com acurácia superior a 97% na classificação automática dos documentos. Os resultados evidenciam o potencial da abordagem para reduzir erros, acelerar demandas e aumentar a produtividade no setor jurídico, contribuindo para um sistema judicial mais ágil e eficiente.

Palavras-chave: Automação Robótica de Processos, Inteligência Artificial, Naive Bayes, Classificação de Documentos Jurídicos.

ABSTRACT

This present work proposes a technological solution for the optimization of legal processes through the integration of Robotic Process Automation (RPA) and Artificial Intelligence (AI). The proposal aims to address the slowness and inefficiency of the Brazilian judiciary system, especially concerning the classification of legal documents. The methodology consisted of extracting texts from public documents, applying statistical metrics to evaluate the importance of a word in individual documents and in document collections, training a machine learning model using the Naive Bayes algorithm, and generating a web interface for automation control. The trained model, along with the vectorizer, was exported using the pickle library, allowing its reuse in automated systems. Tests demonstrated high effectiveness of the system, with an accuracy exceeding 97% in the automatic classification of documents. The results highlight the potential of the approach to reduce errors, accelerate processes, and increase productivity in the legal sector, contributing to a more agile and efficient judicial system.

Keywords: Robotic Process Automation, Artificial Intelligence, Naive Bayes, Legal Document Classification.

INTRODUÇÃO

A lentidão e a ineficiência do sistema judiciário brasileiro são resultado de um conjunto de fatores complexos e interligados. Um dos principais elementos é o volume excessivo de processos que ingressam anualmente no sistema. Em 2023, por exemplo, foram registrados mais de 35,2 milhões de novos casos apenas no âmbito do Poder Judiciário, segundo dados recentes do Conselho Nacional de Justiça (CNJ), um aumento de 9,4% em relação ao ano anterior (Tabela 1). Esses números revelam a dimensão do desafio enfrentado pelos tribunais para analisar e julgar uma imensa quantidade de ações judiciais, pois esse excesso de demandas judiciais causa sobrecarga no sistema, dificultando a análise individualizada dos casos e gerando atrasos consideráveis. A burocracia excessiva, com procedimentos complexos, também contribui para essa morosidade. Além disso, a falta de investimentos em tecnologia e infraestrutura agrava a situação, limitando a capacidade do sistema de atender à demanda.

Tabela 1 - Novos processos jurídicos em 2023

Segmento	Casos Novos 1º Grau	Casos Novos 2º Grau	Total de Casos Novos	Variação percentual com ano anterior
Justiça Estadual	21.845.376	3.315.164	25.160.540	6,7%
Justiça Federal	4.648.275	430.714	5.078.989	13,0%
Justiça do Trabalho	3.283.788	912.754	4.196.542	28,7%
Justiça Eleitoral	74.223	10.408	84.631	-55,6%
Justiça Militar Estadual	2.239	1.619	3.858	-3,2%
Tribunais Superiores			755.425	4,9%
Total	29.856.095	4.670.659	35.282.719	9,4%

Fonte: Conselho Nacional de Justiça

Outro fator importante é a complexidade da legislação brasileira, com suas diversas interpretações e constantes atualizações, o que exige um tempo considerável para análise e compreensão, contribuindo para a lentidão dos processos. Além disso, a cultura organizacional tradicional do Poder Judiciário, muitas vezes resistente a mudanças, dificulta a implementação de novas tecnologias e metodologias de trabalho, perpetuando o ciclo de ineficiência.

Nesse contexto, surgem as seguintes questões: como a Automação Robótica de Processos (*Robotic Process Automation*, RPA) e a Inteligência Artificial (IA) podem ser utilizadas para aprimorar a eficiência e a precisão na classificação de documentos legais? De que maneira essas tecnologias podem contribuir para a redução de erros e para uma gestão de informações mais eficaz no setor jurídico? E, ainda, quais são os principais desafios e oportunidades na implementação dessas soluções no contexto do sistema jurídico brasileiro?

Parte-se da hipótese de que a implementação de um sistema de RPA com Inteligência Artificial para a classificação automática de documentos legais tem o potencial de reduzir significativamente o tempo de processamento e tramitação, diminuir a incidência de erros humanos e aumentar a produtividade dos profissionais do direito, resultando em uma melhoria substancial na eficiência das demandas judiciais.

Diante desse cenário, o objetivo principal deste artigo é desenvolver um sistema de RPA que, a partir do uso de inteligência artificial, seja capaz de classificar documentos jurídicos de forma automática e precisa, visando otimizar os processos em ambientes do setor. Para alcançar esse propósito, propõe-se:

- Analisar os tipos mais comuns e relevantes de documentos jurídicos e suas características distintivas para estabelecer critérios de classificação;
- Desenvolver um sistema RPA para a automação do processo de classificação dos documentos jurídicos;
- Implementar algoritmos de inteligência artificial para treinar o sistema RPA na identificação e categorização precisa dos diferentes tipos de documentos;
- Avaliar a eficácia do sistema desenvolvido em termos de precisão, velocidade e redução de erros em comparação com os métodos manuais tradicionais;
- Propor um modelo de integração do sistema RPA com os fluxos de trabalho existentes em ambientes jurídicos.

Esse objetivo torna-se ainda mais relevante diante da crescente digitalização dos processos jurídicos e do aumento do volume de documentos eletrônicos, o que demanda soluções tecnológicas que possam otimizar a gestão documental. A implementação de um RPA com inteligência artificial pode se apresentar como uma

solução capaz de automatizar tarefas repetitivas, permitindo que os profissionais da área jurídica possam dedicar mais tempo a atividades analíticas e estratégicas, contribuindo então para a redução de erros humanos e para a eficiência dos processos, aspectos cruciais desse setor que lida com prazos e decisões que impactam diretamente a vida das pessoas.

FUNDAMENTAÇÃO TEÓRICA

O processo judicial constitui o conjunto de atos coordenados que busca aplicar a lei a um caso concreto, garantindo a solução de conflitos de maneira justa e imparcial. Para Marques (1997, p. 42), representa um método de resolução de litígios utilizado pelos tribunais, através do qual é garantida a tutela jurisdicional do Estado. Dessa forma, o processo judicial é entendido não apenas como um instrumento, mas como uma ferramenta fundamental para assegurar o acesso à justiça, conforme o artigo 5º, inciso XXXV, da Constituição Federal de 1988.

No Brasil, o processo judicial é regulamentado por códigos específicos, como o Código de Processo Civil (Lei nº 13.105/2015) e o Código de Processo Penal (Decreto-Lei nº 3.689/1941). Nery Júnior e Andrade Nery (2019) destacam que uma das principais funções do Código de Processo Civil é garantir que o direito material seja protegido de forma eficaz, oferecendo instrumentos processuais adequados para a resolução de disputas. O processo caracteriza-se por sua estrutura dialética, onde as partes envolvidas apresentam suas alegações perante um juiz imparcial, que decidirá com base nas provas e argumentos apresentados. Segundo Theodoro Júnior (2020, p. 33), o processo segue uma sequência lógica de atos, conforme as normas jurídicas, permitindo ao juiz proferir uma decisão fundamentada na verdade dos fatos e no direito aplicável.

Ademais, o princípio da duração razoável do processo também é essencial no direito processual contemporâneo. Dinamarco (2016) afirma que o processo deve ser conduzido com eficiência, visando à justiça sem atrasos indevidos e respeitando o direito das partes a uma resolução rápida. Dessa forma, o processo judicial desempenha um papel crucial na administração da justiça, fornecendo mecanismos para a solução pacífica de conflitos e garantindo que os direitos das partes sejam resguardados.

Já quanto à automação, que é definida como o processo de utilização de tecnologias para realizar tarefas com o mínimo de intervenção humana, observamos que tem expandido sua aplicação desde setores industriais até serviços administrativos e jurídicos. Segundo John Diebold (1952), pioneiro no estudo de automação, o conceito envolve o uso de máquinas e sistemas para realizar tarefas repetitivas de maneira mais eficiente, melhorando a produtividade ao reduzir erros e aumentar a consistência na execução de atividades. Groover (2007) destaca que a automação constitui um conjunto de tecnologias para substituir tarefas humanas manuais e ressalta que sua evolução é parte integrante da "quarta revolução industrial" ou Indústria 4.0, envolvendo tecnologias emergentes como inteligência artificial, *machine learning* e *big data*, que ampliam a capacidade das máquinas de tomarem decisões autônomas.

No contexto da automação de processos empresariais e administrativos, surge a *Robotic Process Automation* (RPA), tecnologia de automação de tarefas repetitivas e estruturadas com o uso de *softwares* robôs. Leslie Willcocks (2016, p. 2) define RPA como "o uso de *softwares* que podem imitar as ações humanas em interfaces digitais, como acessar sistemas, mover arquivos e processar transações". A RPA permite às organizações obterem eficiência em grande escala ao automatizar tarefas de rotina, eliminando erros humanos e aumentando a produtividade. Um dos principais benefícios da RPA é sua possibilidade de implementação em sistemas legados sem a necessidade de modificar o código subjacente. Aguirre e Rodriguez (2017, p. 3) destacam que a automação de processos robóticos oferece uma solução de baixo custo para tarefas repetitivas, melhorando a eficiência e reduzindo o tempo de processamento.

Quanto à Inteligência Artificial (IA), ela representa um campo da ciência da computação focado no desenvolvimento de sistemas capazes de realizar tarefas que normalmente requerem inteligência humana. Russell e Norvig (2020) definem a IA como o estudo e design de agentes inteligentes, onde um agente inteligente é um sistema que percebe seu ambiente e toma ações que maximizam suas chances de sucesso em determinado objetivo. A IA engloba diversas abordagens, dentre elas, destaca-se o Aprendizado de Máquina, definido por Domingos (2015) como a capacidade dos computadores de aprender com dados, reconhecendo padrões e automatizando decisões de forma progressiva, e o Processamento de Linguagem

Natural, que permite que máquinas compreendam, interpretem e gerem texto em linguagem humana, conforme explicam Jurafsky e Martin (2020).

No setor jurídico, a adoção de RPA e tecnologias de IA pode transformar atividades como o gerenciamento de documentos, automação de processos de conformidade e otimização do fluxo de trabalho em escritórios de advocacia e departamentos jurídicos. Davenport (2020, p. 87) destaca que essas tecnologias podem reduzir drasticamente o tempo gasto em tarefas rotineiras, permitindo que os profissionais se concentrem em atividades de maior valor agregado, como a análise jurídica e a tomada de decisão estratégica. A automação oferece soluções promissoras ao permitir maior agilidade, precisão e eficiência na gestão de processos, melhorando não apenas a produtividade dos profissionais do direito, mas também tendo o potencial de aumentar o acesso à justiça, reduzindo custos e acelerando a resolução de disputas legais.

METODOLOGIA

Este artigo caracteriza-se como aplicado e exploratório, com abordagem quantitativa, visando desenvolver uma solução tecnológica para a otimização de processos jurídicos através da automação e inteligência artificial. O desenvolvimento do trabalho foi estruturado em fases distintas e complementares, descritas a seguir:

1. Coleta de Documentos: Foi realizada a coleta de documentos jurídicos de diferentes naturezas e tipos, provenientes de bases de dados jurídicas públicas. Desta forma foi possível criar um conjunto de dados representativo que servirá como base para o treinamento e teste do sistema.
2. Classificação de Documentos: Os documentos coletados foram analisados e classificados manualmente com suporte da área jurídica. Esta classificação inicial foi essencial para criar um conjunto de dados rotulados que serviu como referência para o treinamento do sistema de IA.
3. Desenvolvimento do sistema RPA: O sistema de Automação de Processos Robóticos foi desenvolvido utilizando *frameworks* e ferramentas específicas para RPA. O sistema é responsável pela captura dos documentos, seu processamento inicial e encaminhamento para classificação.

4. Implementação de Inteligência Artificial: Esta etapa envolveu o desenvolvimento e aplicação dos componentes de IA do sistema, utilizando técnicas de processamento de linguagem natural e aprendizado de máquina. O modelo foi treinado com o conjunto de dados previamente classificado, permitindo que o sistema aprenda a identificar e categorizar automaticamente diferentes tipos de documentos jurídicos. Foram implementados algoritmos específicos para análise textual e classificação.
5. Testes e Avaliação: O sistema desenvolvido foi submetido a testes para avaliar seu desempenho. Foram utilizadas métricas quantitativas como precisão, *recall* e *F1-score* para medir a acurácia da classificação automática. Além disso, foram realizados testes comparativos com a classificação manual para verificar a eficiência e confiabilidade da solução.

DESENVOLVIMENTO DO SISTEMA RPA COM INTELIGÊNCIA ARTIFICIAL

Coleta e Preparação dos Dados

Inicialmente, a proposta do projeto consistia na utilização de documentos provenientes de ações judiciais, com o intuito de explorar a complexidade e diversidade textual dos autos processuais, de modo a treinar e testar modelos de inteligência artificial aplicados a nosso processo de automação. Essa abordagem nos parecia promissora, considerando o volume expressivo e a diversidade de documentos presentes no Poder Judiciário, o que permitiria simular de forma fidedigna um ambiente real em que o sistema seria eventualmente aplicado.

No entanto, logo nos deparamos com uma série de entraves práticos e legais. Do ponto de vista técnico, o acesso aos documentos judiciais revelou-se significativamente limitado, tanto pela dificuldade de obtenção em larga escala quanto pelas restrições impostas ao acesso direto a esses documentos nos sistemas dos tribunais. O principal obstáculo, contudo, foi o de natureza jurídica: a Lei Geral de Proteção de Dados Pessoais (LGPD), que impõe restrições severas ao tratamento de dados sensíveis e identificáveis, ainda que estejam presentes em documentos de natureza pública. Mesmo com a possibilidade de anonimização, o risco de exposição indevida de informações pessoais e a complexidade do processo de higienização dos dados desaconselharam essa linha de coleta.

Diante desse cenário, optamos por redirecionar o foco do projeto para o uso de documentos públicos de natureza institucional, amplamente disponibilizados por órgãos como os Ministérios Públicos dos Estados do Espírito Santo (MPES) e de Minas Gerais (MPMG). Esses documentos, por tratarem de manifestações, recomendações, denúncias, pareceres e outras peças produzidas no exercício das funções institucionais dos MPs, são não apenas acessíveis ao público, como também representam um excelente ambiente para aplicação de nosso sistema de categorização automatizada.

Com a decisão de utilizar os Ministérios Públicos como fontes de dados, iniciamos o processo de coleta e organização dos documentos. Os arquivos disponibilizados por esses órgãos, todos no formato PDF, foram obtidos por meio da navegação e download manual e automatizado a partir de seus portais institucionais, respeitando os limites legais de uso de dados públicos. Após a coleta, os documentos passaram por uma etapa essencial de separação, na qual realizamos a classificação de cada item conforme sua natureza ou tipo documental — por exemplo, “licitações” e “contratos”. Essa classificação, realizada manualmente, foi fundamental para a criação de um conjunto de dados rotulados, que serviria posteriormente para o treinamento supervisionado dos modelos de Inteligência Artificial (IA).

Superada essa etapa de categorização, desenvolvemos um *script* em *Python* com o objetivo de realizar o processamento textual dos documentos. Esse *script* foi responsável por realizar a extração do conteúdo textual dos arquivos PDF, utilizando a biblioteca especializada *PDFMiner*. Em seguida, o texto bruto extraído de cada documento foi vinculado à sua respectiva categoria previamente definida. O *script* então consolidou todas essas informações em uma estrutura tabular, gerando um arquivo no formato CSV (*Comma-separated values*, Valores separados por vírgula) contendo duas colunas principais: a primeira com o conteúdo textual da primeira página de cada documento, e a segunda com sua respectiva classificação.

No processo de extração textual, optou-se por coletar o conteúdo exclusivamente da primeira página de cada documento PDF. Esta decisão metodológica foi fundamentada na premissa de que, no contexto dos documentos públicos analisados provenientes dos Ministérios Públicos do Espírito Santo (MPES) e de Minas Gerais (MPMG), as primeiras páginas frequentemente contêm elementos

cruciais para a identificação do tipo documental, tais como cabeçalhos informativos, a qualificação inicial da peça ("Contrato", "Licitação", "Notas de Empenho", "Sanção" etc.), e, por vezes, um resumo preliminar ou ementa. Embora a extração do conteúdo completo de cada documento pudesse, em teoria, fornecer um contexto mais rico para a classificação, essa abordagem resultaria em um volume de dados textuais significativamente maior para processamento e vetorização (via TF-IDF), o que demandaria maior capacidade computacional e tempo de execução, e poderia introduzir termos menos relevantes para a discriminação inicial entre classes.

Portanto, a escolha pela primeira página representou um trade-off pragmático para este estudo, permitindo validar a viabilidade da classificação automática baseada em informações salientes e com um custo computacional razoável para o desenvolvimento do protótipo.

O arquivo CSV com o texto extraído e sua classificação foi essencial para a fase seguinte do projeto, permitindo tanto a exploração estatística dos dados quanto a aplicação direta em modelos de aprendizado de máquina para tarefas de categorização automática. Ademais, ao automatizar o processo de extração e formatação dos dados, foi possível acelerar significativamente o fluxo de preparação dos dados, garantindo consistência e reprodutibilidade para futuras iterações do sistema.

Processamento e Vetorização dos Textos

Dando prosseguimento ao trabalho, de posse do arquivo CSV estruturado, prosseguimos para a etapa de preparação dos dados textuais para uso em modelos de aprendizado de máquina. Essa etapa teve como foco a transformação dos textos brutos em representações numéricas por meio da técnica conhecida como TF-IDF (*Term Frequency-Inverse Document Frequency*, Frequência do Termo–Inverso da Frequência nos Documentos). Essa abordagem estatística mede a importância de uma palavra em um documento, levando em consideração não apenas a frequência com que ela aparece no dado documento (TF), mas também o quão rara ela é no conjunto total de documentos (IDF).

Em outras palavras, termos frequentes em um único documento, mas incomuns nos demais, recebem maior peso. Já termos genéricos e recorrentes em todos os textos

têm pesos reduzidos. Essa técnica permite capturar com mais precisão os termos que melhor caracterizam cada documento, tornando-os mais informativos para o modelo de classificação. O resultado desse processo é uma matriz numérica em que cada documento é representado por um vetor de pesos associados às palavras mais relevantes do corpus — uma estrutura ideal para alimentar algoritmos de aprendizado supervisionado.

Tabela 2 - Representação parcial do vetor TF-IDF

desempenho	desenvolvidos	desenvolvimento	desequilíbrio	desfavor	designada
0.07492203422	0.0	0.0	0.0609672614	0.0	0.0
0.0	0.0	0.0	0.0	0.0	0.22257678156
0.0	0.08492203422	0.0	0.0610940573	0.0	0.0
0.08493488996	0.0	0.0	0.0	0.0	0.11865858181
0.08732103195	0.0	0.0	0.0915995594	0.0	0.0

Fonte: Desenvolvido pelos autores

Essa transformação foi implementada por meio de um novo *script* em *Python*. Um ponto crucial nesta etapa foi a inclusão de um conjunto de *stop words* — palavras muito comuns no nosso idioma, como artigos e preposições — que, por sua alta frequência e baixo valor semântico, poderiam interferir negativamente na qualidade do modelo. Assim, definimos manualmente uma lista de palavras irrelevantes em português, como "o", "a", "e", "é", "que", "de", entre outras, que foram explicitamente removidas durante a vetorização. Isso nos permitiu uma limpeza mais eficaz dos dados textuais, concentrando o modelo apenas nos termos com maior potencial discriminativo entre as classes.

A partir disso, o vetor TF-IDF foi então gerado a partir dos textos contidos na primeira coluna do CSV, e a estrutura resultante — uma matriz esparsa de alta dimensionalidade — foi então convertida para um *Data Frame* (uma estrutura de dados que organiza dados em uma tabela bidimensional de linhas e colunas, semelhante a uma planilha) contendo cada termo/palavra como uma coluna e seus respectivos pesos em cada documento como valores. Em seguida, a matriz TF-IDF foi exportada para um novo arquivo CSV, que passou a ser a base de dados utilizada para os experimentos e treinamento com algoritmos de classificação

supervisionada. Por fim, o objeto vetorizador de texto foi salvo como um arquivo serializado, permitindo sua reutilização futura para a inferência, uma vez que essa matriz funciona como o vocabulário de referência necessário para transformar novos textos em vetores TF-IDF consistentes com os utilizados durante o treinamento.

Treinamento do Modelo de Classificação

Com o vetor TF-IDF gerado e estruturado, iniciamos a fase de treinamento do modelo de classificação, que representa a inteligência artificial do nosso sistema de RPA. O algoritmo escolhido para esta tarefa foi o *Multinomial Naive Bayes*, uma variante do classificador *Naive Bayes* especialmente adequada para tarefas de classificação de texto. A escolha deste algoritmo se deve a ele ser amplamente reconhecido na literatura por sua eficácia em problemas de categorização textual, apresentando vantagens significativas como simplicidade computacional, robustez a dados com alta dimensionalidade (grande número de características, no nosso caso cada palavra ou termo) e capacidade de lidar eficientemente com vetores esparsos (onde a maioria dos elementos são zero), que são características que se alinham perfeitamente com a natureza dos dados do vetor que foi preparado. Além disso, este algoritmo é particularmente eficiente em cenários onde o volume de dados não é extremamente grande, mas a qualidade e a representatividade das amostras são altas, como era o caso de nossa coleção de documentos jurídicos coletados, que possuía um total de 500 documentos.

O processo de treinamento seguiu a metodologia padrão de aprendizado supervisionado, iniciando com a divisão do conjunto de dados em dois subconjuntos distintos: um para treinamento e outro para teste. Esta separação foi realizada utilizando um parâmetro *test size* de 0.4, o que significa que 40% dos dados foram reservados para teste e 60% para treinamento, resultando em 200 e 300 documentos para cada conjunto, respectivamente.

Uma questão crítica identificada durante a análise dos dados foi o desequilíbrio significativo entre as classes de documentos. A coleção completa continha quatro categorias — contratos (121 documentos), licitações (176), notas de empenho (174) e sanções (29) — que apresentavam uma distribuição desigual. Essa disparidade era particularmente acentuada na classe de sanções, substancialmente

sub-representada, o que poderia comprometer severamente o desempenho do modelo, levando-o a desenvolver um viés em favor das classes majoritárias.

Para mitigar esse problema, implementamos a técnica SMOTE (*Synthetic Minority Oversampling Technique*), uma abordagem de balanceamento que gera amostras sintéticas das classes minoritárias através de interpolação entre exemplos existentes. A estratégia utilizada foi a '*not majority*', que aplica sobreamostragem exclusivamente às classes não majoritárias, elevando todas ao mesmo número de exemplos da classe majoritária — a de licitações.

Diferentemente de técnicas mais simples, como a duplicação de amostras, o SMOTE cria novos pontos de dados que se situam no espaço entre amostras reais das classes minoritárias. Isso aumenta a diversidade do conjunto de treinamento sem simplesmente replicar dados, garantindo representação equitativa entre as classes enquanto preserva a distribuição natural da classe majoritária.

Com as classes devidamente balanceadas, iniciou-se o treinamento do modelo utilizando o algoritmo *Multinomial Naive Bayes*, conforme mencionado anteriormente. O algoritmo fundamenta-se no teorema de Bayes e opera sob a premissa "ingênua" de independência condicional entre as características, assumindo que cada palavra no documento contribui independentemente para a classificação.

O processo de treinamento consistiu no cálculo das probabilidades condicionais necessárias para o funcionamento do algoritmo. Durante esta etapa, o modelo associou os padrões de palavras presentes nos vetores TF-IDF com suas respectivas categorias, construindo um modelo probabilístico capaz de estimar a probabilidade de novos documentos pertencerem a cada uma das classes definidas. Para classificar então um novo documento, o algoritmo calcula a probabilidade posterior de pertencimento a cada classe possível, e o resultado final é obtido através da comparação dessas probabilidades calculadas, sendo o documento atribuído à categoria que apresenta a maior probabilidade.

A escolha do *Multinomial Naive Bayes* mostrou-se adequada para esta tarefa de classificação textual em detrimento de outros algoritmos utilizados com o mesmo fim, como *Random Forest*, *Support Vector Machine* (SVM) e modelos baseados em

transformers como BERT. Embora o SVM apresente excelente desempenho em problemas de classificação textual e o *Random Forest* ofereça robustez contra *overfitting*, que ocorre quando o modelo se ajusta excessivamente aos dados de treino e perde capacidade de generalização, ambos demandam maior poder computacional e tempo de treinamento, especialmente em conjuntos de dados de grande dimensionalidade como os gerados pela vetorização TF-IDF. Já os modelos *transformer* como o BERT requerem recursos computacionais substancialmente superiores, principalmente em termos de memória. O *Naive Bayes*, por sua vez, oferece uma combinação equilibrada de simplicidade computacional e eficiência de treinamento, características essenciais para o escopo deste trabalho, aliadas a um desempenho robusto que, embora não atinja os níveis máximos de acurácia dos modelos mais complexos, demonstrou ser bastante alto na tarefa de classificação textual proposta, justificando sua adoção como solução otimizada para os recursos disponíveis.

Avaliação do Desempenho do Modelo

Após o treinamento, o modelo foi submetido a uma avaliação utilizando o conjunto de teste reservado, composto por 200 documentos não vistos durante a fase de treinamento. Os resultados obtidos foram excelentes, demonstrando não apenas alta precisão, mas também um desempenho equilibrado entre todas as classes de documentos.

O modelo alcançou uma acurácia geral de 97,50% (Tabela 3), classificando corretamente 195 dos 200 documentos, com apenas 5 erros de classificação, sendo um destaque a classe de “Licitações”, que teve um desempenho perfeito — sem falsos positivos ou falsos negativos. Isso reflete não só a qualidade dos dados coletados, mas também o processamento textual, onde houve o uso eficaz da técnica SMOTE para balanceamento das classes e a compatibilidade do algoritmo selecionado com a tarefa de categorização proposta.

É importante destacar que, mesmo com a presença de uma classe minoritária — a categoria “sanções”, que originalmente representava menos de 5% do total de documentos —, o modelo foi capaz de manter boa capacidade de generalização

sem favorecer classes majoritárias, o que novamente reforça a eficácia da estratégia de balanceamento aplicada e a robustez do modelo treinado.

Tabela 3 - Reporte de classificação

Classe do documento	<i>precision</i>	<i>recall</i>	<i>f1-score</i>	<i>support</i>
Contratos	0,92	0,98	0,95	48
Licitações	1,0	1,0	1,0	59
Notas de Empenho	1,0	0,95	0,97	80
Sanções	0,93	1,0	0,96	13
Acurácia			0,97	200
Média Macro	0,96	0,98	0,97	200
Média Ponderada	0,98	0,97	0,98	200

Fonte: Desenvolvido pelos autores

Para garantir a operacionalização do sistema e sua integração com o processo de RPA, o modelo treinado também foi serializado e salvo utilizando a biblioteca *joblib*. Este arquivo contém não apenas os parâmetros aprendidos pelo algoritmo, mas também toda a estrutura necessária para realizar inferências sobre novos documentos. Desta forma, podemos permitir que o modelo treinado seja carregado e utilizado de forma eficiente em diferentes contextos e aplicações.


Desenvolvimento da Interface Web

Munidos de tudo que era necessário, partimos para a etapa de integração prática da solução em um ambiente de fácil utilização. Para isso, desenvolvemos um sistema *web* local utilizando o *framework Django*, com o objetivo de disponibilizar uma interface simples e funcional para um eventual usuário final. Nesta interface, o usuário consegue inserir o caminho da pasta de origem onde estão os documentos que serão classificados e o caminho da pasta de destino das previsões feitas pelo modelo, onde os arquivos ficarão devidamente organizados em pastas de acordo com sua classe.

Essa interface serve como ponto de convergência entre o *pipeline* de IA e o processo de automação robótica (RPA), viabilizando a aplicação prática do sistema


em fluxos de trabalho reais, sem necessidade de interação com código-fonte. Ao inserir os diretórios e acionar o sistema, os arquivos da pasta de entrada são processados um a um: seus textos são extraídos, vetorizados com o mesmo vocabulário do treinamento e classificados pelo modelo *Naive Bayes* previamente salvo. Em seguida, cada arquivo é movido para a subpasta correspondente à sua categoria prevista, criada dinamicamente dentro da pasta de saída especificada.

Figura 1 - Fluxograma da *pipeline* do Sistema



Fonte: Desenvolvido pelos autores

A fim de validar a capacidade de generalização do modelo em um cenário real, foi conduzido um teste adicional (Figura 2) com 20 documentos provenientes tanto do MPRJ quanto do MPES, sendo 5 documentos de cada uma das quatro classes estabelecidas. Este teste apresentou características particularmente desafiadoras, uma vez que nenhum documento do MPRJ foi utilizado como fonte de dados durante qualquer etapa do treinamento do modelo. Mesmo diante desta limitação, o sistema demonstrou excelente capacidade de adaptação, classificando corretamente todos os 20 documentos testados, o que comprova sua robustez e capacidade de generalização para dados de diferentes origens institucionais.

Figura 2 - Sistema *web* com interface

127.0.0.1:8000

Classificador de Documentos Jurídicos

Pasta de Origem:
/home/ghccalanzani/Downloads/tcc-faesa-main/Input

Pasta de Destino:
/home/ghccalanzani/Downloads/tcc-faesa-main/ouput

Enviar

Resultado do Processamento:

- Total Processados: 20
- Total com Erros: 0

Arquivos por categoria:

- contratos: 5
- licitacoes: 5
- notasempenho: 5
- sancoes: 5

Fonte: Desenvolvido pelos autores

Este sistema *web* representa a etapa final do projeto, consolidando todo o fluxo de trabalho em uma aplicação prática, acessível e de fácil utilização. Essa automação não apenas agiliza o processo de categorização, como também minimiza a intervenção manual e os riscos de erro humano. Dessa forma, a ferramenta se mostra apta a ser incorporada a rotinas administrativas de órgãos públicos ou privados que lidam com grandes volumes de documentos jurídicos, promovendo maior eficiência, organização e padronização no tratamento dessas informações.

CONSIDERAÇÕES FINAIS

O presente artigo teve como objetivo principal o desenvolvimento de um sistema de automação robótica de processos (RPA), aliado a técnicas de inteligência artificial, para classificar documentos jurídicos de forma automática e precisa. Essa proposta surgiu da necessidade de otimizar fluxos operacionais em ambientes jurídicos, marcados por um alto volume de informações e pela repetitividade de tarefas administrativas.

Ao longo do estudo, foi possível alcançar os objetivos propostos, desde a análise dos documentos até a implementação e avaliação de um modelo funcional. Os resultados demonstram que o uso integrado de RPA e aprendizado de máquina

proporciona ganhos significativos em agilidade, padronização e redução de erros manuais no processo de triagem documental. A solução que propusemos não apenas se mostrou tecnicamente viável, como também evidenciou potencial para aplicação prática em escritórios de advocacia, departamentos jurídicos de empresas e instituições públicas.

Do ponto de vista acadêmico, essa pesquisa contribui para o avanço do debate sobre transformação digital no setor jurídico, ao aplicar técnicas de ciência da computação em um domínio tradicionalmente burocrático. Além disso, oferece um exemplo concreto de como abordagens interdisciplinares podem trazer soluções inovadoras para problemas operacionais recorrentes.

Apesar dos resultados positivos, algumas limitações devem ser reconhecidas. O modelo foi treinado e testado com um conjunto específico de documentos, o que limita sua generalização para outras realidades, logo para outros contextos institucionais se faz necessário outros conjuntos de dados e novo treinamento. A precisão do sistema também pode ser impactada por variações linguísticas, formatos não padronizados e documentos digitalizados não selecionáveis, que não permitem a extração de maneira otimizada tal como construímos.

Como sugestão para melhorias ou projetos futuros, recomendamos a ampliação do conjunto de dados com uma base documental mais diversificada, o aprimoramento do modelo com técnicas mais avançadas de Processamento de Linguagem Natural, integração com sistemas de gestão processual existentes e técnicas mais avançadas de extração textual baseadas em reconhecimento óptico de caracteres.

Por fim, este estudo reafirma a importância da adoção de soluções automatizadas no contexto jurídico e reforça a relevância da inteligência artificial como aliada na modernização de processos. A proposta aqui apresentada representa um passo concreto em direção a uma atuação mais eficiente, estratégica e tecnologicamente orientada no campo do Direito.

REFERÊNCIAS

AGUIRRE, Santiago; RODRIGUEZ, Andrés. *Automation in Financial Services with RPA: A Pragmatic Approach*. IEEE Conference, 2017.

ASHLEY, Kevin D. *Artificial Intelligence and Legal Analytics: New Tools for Law Practice in the Digital Age*. Cambridge: Cambridge University Press, 2017.

CARVALHO, João Cláudio Nunes. *O algoritmo Naive Bayes - descrição e implementação em Python*. Ceará: 2023. Disponível em: <https://scikit-learn.org/stable/modules/naive_bayes.html#gaussian-naive-bayes>. Acesso em: 10 maio 2025.

DAVENPORT, Tom. *The AI Advantage: How to Put the Artificial Intelligence Revolution to Work*. MIT Press, 2020.

DIEBOLD, John. *Automation: The Advent of the Automatic Factory*. Van Nostrand, 1952.

DINAMARCO, Cândido Rangel. *Instituições de Direito Processual Civil*. São Paulo: Malheiros, 2016.

DOMINGOS, Pedro. *The Master Algorithm: How the Quest for the Ultimate Learning Machine Will Remake Our World*. Basic Books, 2015.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. The MIT Press, 2016.

GROOVER, Mikell P. *Automation, Production Systems, and Computer-Integrated Manufacturing*. Pearson, 2007.

JURAFSKY, Daniel; MARTIN, James H. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. 2.ed. Prentice Hall, 2001.

MARQUES, José Frederico. *Instituições de Direito Processual Civil*. Rio de Janeiro: Forense, 1997.

NERY JÚNIOR, Nelson; NERY, Rosa Maria de Andrade. *Código de Processo Civil Comentado*. São Paulo: Revista dos Tribunais, 2019.

NORVIG, Peter; RUSSELL, Stuart. *Inteligência Artificial*. 3.ed. GEN LTC, 2013.

SCIKIT-LEARN. *Supervised learning: Gaussian Naive Bayes*. Disponível em: <https://scikit-learn.org/stable/modules/naive_bayes.html#gaussian-naive-bayes>. Acesso em: 05 maio 2025.

SCIKIT-LEARN. *Over-sampling methods: SMOTE*. Disponível em: <https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTE.html>. Acesso em: 24 abr. 2025.

THEODORO JÚNIOR, Humberto. *Curso de Direito Processual Civil*. 58. ed. Rio de Janeiro: Forense, 2020.

WILLCOCKS, Leslie; LAULU, John; LACITY, Mary. *Service Automation: Robots and the Future of Work*. SB Publishing, 2016.