

APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NA SEGURANÇA PATRIMONIAL

APPLICATION OF ARTIFICIAL INTELLIGENCE IN ASSET SECURITY

BRENO JANTORNO FERREIRA
Graduando em Ciência da Computação
brenojantorno1@gmail.com

JOÃO BATISTA MUYLAERT DE ARAUJO JUNIOR
Graduando em Ciência da Computação
jbj.vix@hotmail.com

HOWARD CRUZ ROATTI
Prof.º Msc. Centro Universitário FAESA
howard.cruz@faesa.br

RESUMO

Em uma sociedade com alto índice de criminalidade, é salutar desenvolver ferramentas que automatizem o trabalho de antecipação à atuação criminosa. Assim, há indícios de ser possível treinar uma inteligência artificial para que identifique determinados comportamentos, a exemplo de pessoas portando facas e armas de fogo, de maneira a antever a prática de crimes. No presente estudo, a acurácia do modelo apresentado foi de 68%, ainda insuficiente para efetiva comprovação da proposta. O modelo proposto pode ser adotado como medida de proteção patrimonial, a ser utilizado por empresas e autoridade policial na antecipação de crimes.

Palavras-chave: Inteligência artificial; segurança patrimonial; detecção de objetos; identificação de armas.

ABSTRACT

In a society with a high crime rate, it is beneficial to develop tools that automate the work of anticipating criminal activity. Thus, there are indications that it is possible to train an artificial intelligence to identify certain behaviors, such as people carrying knives and firearms, in order to anticipate the commission of crimes. In the present study, the accuracy of the presented model was 68%, still insufficient to effectively prove the proposal. The proposed model can be adopted as a measure of asset protection, to be used by companies and police authorities in anticipating crimes.

Keywords: Artificial intelligence; property security; object detection; weapons identification.

INTRODUÇÃO

O Brasil é um dos países que sofre com maior incidência de crimes (LUCENA, 2021), sendo que parte deles é praticada contra o patrimônio de pessoas e empresas (FÓRUM SEGURANÇA, 2022). Somando-se a isso, o volume de crimes de maior gravidade (crimes contra a vida e contra a integridade das pessoas) e o baixo êxito nas investigações policiais (BATISTA, 2021) denotam a necessidade de antecipação à atuação criminosa.

Apesar de serem facilmente encontrados sistemas de segurança para imóveis no mercado, a sua maioria se resume à gravação de imagens e alarmes, sendo apenas reativos no caso de uma invasão do imóvel (JOHNSON CONTROLS, 2018).

Com esta pesquisa pretende-se responder as seguintes perguntas: é possível desenvolver um programa de Inteligência Artificial (IA) que aprenda a identificar um comportamento suspeito específico (portar arma de fogo ou faca), antecipando a ação de meliantes? O sistema conseguirá identificar um sujeito armado? Qual a melhor métrica a ser utilizada para identificar o resultado da aprendizagem pela IA?

A realização de identificação de pessoas com comportamentos objetivamente considerados suspeitos, feita de forma automatizada por uma inteligência artificial pode auxiliar na identificação da atuação de criminosos, reforçando a proteção dessas pessoas e do próprio patrimônio, além de reforçar a atuação policial, mesmo para uma abordagem reativa (após a ocorrência do fato criminoso).

No que tange ao objetivo geral da pesquisa, considera-se o desenvolvimento de um modelo de aprendizagem de máquina de visão computacional que, a partir de um comportamento específico que gere suspeita – portar uma arma de fogo ou faca – possa identificá-lo no momento em que ocorrer, permitindo o reforço de medidas de segurança e confirmação do ataque criminoso.

No que tange aos objetivos específicos da pesquisa, considera-se:

- Identificar um comportamento suspeito específico (portar arma de fogo ou faca);

- Apresentar o conceito de Inteligência Artificial e como esta funciona avaliando imagens e vídeos;
- Desenvolver um modelo de aprendizagem de máquina de visão computacional com habilidade para identificar o referido comportamento suspeito, a partir de imagens e vídeos;
- Apontar índices de erros e acertos encontrados na demonstração, obtidos pelas métricas adotadas ao longo do estudo.

Enquanto justificativa do universo temático abordado, considera-se que a antecipação a uma atuação criminosa, ao se observar previamente a presença de pessoas com comportamentos suspeitos na região, os proprietários de imóveis ou empresas de segurança contratadas para vigiá-los poderão reforçar as medidas defensivas contra uma invasão, evitando-a ou dificultando-a.

Ainda, no caso de retardo da atuação criminosa, pode ser em tempo suficiente para acionamento da autoridade policial, evitando-se o objetivo principal do meliante, a redução do patrimônio da vítima.

METODOLOGIA DE DESENVOLVIMENTO

Essa é uma pesquisa bibliográfica utilizando livros, teses e artigos para o desenvolvimento de uma inteligência artificial (IA) que realize a análise de uma imagem ou vídeo para que possa fazer a detecção do objeto pré-determinado (arma de fogo ou faca). Sendo assim, para atingir os objetivos geral e específicos, e, eventualmente, comprová-los, o estudo será desenvolvido conforme as seguintes fases:

1. Pesquisa e leitura bibliográfica para a compreensão do tema abordado;
2. Análise de possíveis arquiteturas de modelos preditivos que solucionem o problema proposto e técnicas disponíveis que melhor se encaixem no escopo do projeto;
3. Catalogação do *dataset* (separação de imagens e detalhamento de dados para treino), seguida do desenvolvimento de algoritmo;

4. Realização dos processos de *data augmentation* no *dataset* e início dos processos de treino da IA;
5. Plotagem de métricas de avaliação do modelo, com coleta e avaliação dos resultados obtidos;
6. Apresentação de protótipo.

DEFINIÇÃO DE SITUAÇÃO SUSPEITA

Apesar de não ser o enfoque deste estudo o aprofundamento sobre as teorias criminais, fato é que a legislação autoriza que um agente policial aborde uma pessoa com comportamento suspeito, conforme prevê o artigo 244 do Código de Processo Penal Brasileiro:

Art. 244. A busca pessoal independe de mandado, no caso de prisão ou quando houver fundada suspeita de que a pessoa esteja na posse de arma proibida ou de objetos ou papéis que constituam corpo de delito, ou quando a medida for determinada no curso de busca domiciliar.

Por sua vez, diante da subjetividade na interpretação dessa previsão legal, a doutrina de orientação aos policiais, que são os agentes públicos aptos a concretizarem a abordagem prevista nesse artigo, classifica os suspeitos em dois grupos (NEUMANN, 2001):

2) Suspeito fundado

É aquela pessoa que reúne determinadas características ou é encontrada em situação ou conduta ou com objetos que induzam o agente policial a visualizá-la como sendo, potencial ou efetivamente, autor de delito, proporcionando uma coincidência de semelhanças ou uma relação de quase-certeza entre a pessoa abordada e o presumindo ou certo infrator penal.

3) Suspeito Intuído

É aquela pessoa que, em razão das circunstâncias de conduta, tempo e/ou lugar desperta no policial uma presunção de ameaça à tranquilidade pública, embora tal desconfiança não possua relação direta com determinado delito.

A legislação estabelece como crime o porte ilegal de arma, relacionado à circulação de arma de fogo sem a devida autorização (art. 14, Lei 10.826/2003 - Estatuto do Desarmamento). Então, para as armas brancas (facas, machados, facões, canivetes,

por exemplo), por exclusão, aplica-se o art. 19 do Decreto-Lei 3.688/41 – Lei das Contravenções Penais, que proíbe livre o trânsito delas.

Uma vez apontadas as situações consideradas suspeitas segundo o mister policial, resta saber se uma máquina consegue aprender a identificá-las, a partir de um comportamento específico (portar uma arma ou uma faca) e se é possível estabelecer, por métrica, o êxito nessa identificação.

VISÃO COMPUTACIONAL

Uma das maiores empresas que desenvolvem equipamentos eletrônicos e tecnológicos do mundo, a Intel®, aproveita seu portfólio para explicar quais são os principais usos da visão computacional. Ali se observa a necessidade de adoção de equipamentos de entrada de dados, como câmeras, utilização de nuvem para processamento e guarda de enorme volume de dados e *softwares* específicos que permitam a uma Inteligência Artificial enxergar objetos, identificando-os (INTEL, 2022).

Essa visão computacional é obtida a partir da realização de uma série de treinos, sem os quais o reconhecimento torna-se impossível.

Dentro desses conceitos, portanto, é que o presente trabalho ganhará tônus, buscando reconhecer pelo menos um comportamento suspeito de pessoa (portar arma ou faca), o que pode colocar em risco o patrimônio público ou privado.

Assim, pretende-se a utilização da visão computacional para que o modelo de aprendizagem de máquina idealizado consiga enxergar referido comportamento, tal qual um ser humano faria.

MACHINE LEARNING

Enquanto a ideia de visão computacional denota a maneira como um computador enxerga, o conceito de *machine learning* (ou aprendizagem de máquina) relaciona-se a como uma máquina pode ser instruída a aprender de maneira automatizada (ALECRIM, 2018).

Para receber essa instrução, o computador não precisa realizar a mesma quantidade de operações simultâneas que um cérebro humano, mas ser orientada a focar em

quantidade bem menor. Isso, inclusive, permitirá que, a partir das primeiras instruções, a máquina possa realizar atividades de treino e aprendizagem com autonomia.

No caso específico de aprendizagem envolvendo imagens, é importante que se tenha uma base de imagens suficiente para permitir ao computador aprender a classificação do que é o objeto a ser identificado, bem como, o que não é. A quantidade de dados envolvendo esse conhecimento inicial, portanto, depende da complexidade do que se pretende que a máquina aprenda.

APRENDIZADO SUPERVISIONADO

Aprendizado supervisionado é uma metodologia que utiliza dados pré-definidos e estruturados para criar uma função capaz de desenvolver a habilidade de mapear e prever uma saída. Nesse sentido, demanda que os dados fornecidos possuam entrada e saída (RUSSEL, 2013).

Definindo-se qual será o resultado, dada uma entrada, é possível que o modelo aprenda iterativamente a partir das informações que recebeu.


Ademais, esses dados fornecidos servirão como suporte para o modelo e, dessa maneira, quando este for realizar a predição da saída, ele se utilizará dessa informação recebida, permitindo o ajuste nas predições e auxiliando no processo através das métricas obtidas.

REDES NEURAIS ARTIFICIAIS

Redes neurais artificiais se inspiraram no sistema nervoso dos seres humanos, no processo destes que envolve a captura, processamento e propagação de uma informação, alcançando uma conclusão pretendida e efetuando uma decisão calculada (CARVALHO, 2009).

A célula básica do sistema nervoso, o neurônio, serviu de exemplo à elaboração de um sistema computacional de redes neurais, pois as funções e algoritmos desenvolvidos buscam aplicar as mesmas funções e características de três partes dessa célula humana (Figura 1).

Figura 1 - Estrutura de um neurônio



Fonte: ASU, 2011

Conforme demonstrado na Figura 1, o receptor de impulsos (dendritos) é o responsável por receber os sinais de outros neurônios, sendo tal função realizada na forma de entrada de dados pela camada de entrada; o corpo celular, que processa o sinal recebido e efetua a tomada de decisão, sendo equivalente ao processamento das somatórias dos pesos, cujo resultado serve para ativar ou não a função; finalmente, os terminais axônicos, que replicam o sinal desenvolvido no corpo celular para as demais células, atividade que é realizada pela camada de saída (SZYMK, 2011).


Funções de ativação

Ao trabalhar com redes neurais, necessita-se de funções de ativação para decidir se o dado recebido do corpo celular deve ativar o neurônio. Caso ativado, o seu resultado é propagado para o próximo neurônio da estrutura.

Portanto, ele realiza a tarefa primordial de definir, através de funções do plano cartesiano, qual linha de pensamento a rede neural deve seguir, uma vez que o seu resultado estabelece a continuidade ou não daquele neurônio. Ademais, serão apresentadas duas funções escolhidas entre as várias alternativas (*Linear Function*, *Leaky ReLU*, *ReLU*, *Sigmoid*, *Hyperbolic*, *Softplus* e *Softmax*, por exemplo), que detalham o funcionamento dessa etapa do processo.

Informalmente, a função *Rectified Linear Unit* (ReLU) retém somente elementos positivos e descarta todos os elementos negativos, definindo as ativações correspondentes para 0. Para ganhar alguma intuição, pode-se exibir a função de ativação que é linear por partes (ZHANG, 2022).

A partir da Figura 2, observa-se a representação da função que recebe o valor máximo de uma dada entrada. Caso o valor seja maior que zero, a sua saída será um número positivo, caso contrário ela retornará zero.




Fonte: D2L, 2021

A função *Softplus* é considerada uma versão mais suave da ReLU, contendo um formato similar a desta, mas se diferenciando por apontar qualquer derivação diferente de zero (PATTERSON; GIBSON, 2017).

Pela Figura 3, nota-se a comparação das funções *Softplus* e ReLU, sendo que a primeira leva em consideração valores negativos, algo não alcançado pela segunda. Dessa forma, mesmo que o resultado do cálculo seja entre menos três e zero, por exemplo, o neurônio será ativado, evitando-se a morte dele e permitindo que a rede continue a sua propagação. Essa conjuntura pode se converter em um resultado positivo na classificação do dado que se deseja prever.

Figura 3 – Visualização das funções de ativação ReLU e *Softplus*



Fonte: PATTERSON; GIBSON, 2017

Backpropagation

Backpropagation refere-se ao método de calcular os parâmetros do gradiente de uma rede neural. Em resumo, o método atravessa a rede em ordem reversa, da saída para a camada de entrada, de acordo com a regra da cadeia do cálculo (ZHANG, 2022).

Quando uma rede está sendo treinada, em sua criação, serão estabelecidos os pesos para cada ligação de forma aleatória. Após o seu fluxo de treinamento passar pela camada, conclui retornando uma saída. Esta, por sua vez, é comparada a um resultado esperado, calculando assim a sua perda.

A informação obtida auxilia na redistribuição dos pesos entre camadas, permitindo ao modelo atualizar todos esses pesos entre camadas, efetuando o caminho inverso, da saída para o começo, efetuando o processo denominado *Backpropagation*.

Os pesos entre camadas funcionam como chave interpretativa do algoritmo, pois eles contêm o conhecimento adquirido com o passar do tempo/treino. É através dele que o *backpropagation* repassa o conhecimento pelas camadas da rede neural.

Residual blocks e Skip connections


Utiliza-se a técnica *residual blocks* quando há a necessidade de aumentar a profundidade de uma rede neural, permitindo maior capacidade de abstração.

A inclusão de mais camadas não resolve o problema, pois pode provocar a degradação do dado, que é a perda da precisão na medida em que a informação avança para camadas mais profundas da rede, diminuindo as informações que deveriam ser aprendidas por esta.

A resolução da questão ocorre por atalhos entre as camadas ou *skip connections*, otimizando a transferência da informação entre elas (ZHANG, 2022).

Pela Figura 4 fica demonstrado como se dá esse salto entre as camadas, de maneira que aquela informação residual, que não seria aproveitada, passa a ser aprendida pela camada de saída da rede neural.

Figura 4 – Salto entre as camadas




Fonte: TOWARDSDATASCIENCE, 2018

OBJECT DETECTION: BOUNDING BOX E NON-MAXIMUM SUPRESSION

De forma bastante simplificada, a ideia de *object detection* refere-se à utilização de um conjunto de coordenadas que permita a identificação de um objeto em uma imagem, seguido da classificação desse objeto dentro de um escopo de classes pré-definidas.

Assim, adota-se a *bounding box* ou caixa delimitadora que é uma figura geométrica (Figura 5) que buscará envolver um objeto dentro de uma imagem, a partir de uma posição específica (conforme determinado em um plano cartesiano) ou identificar algo em específico, como o rosto de alguém determinado (IBM, 2021).


Figura 5 – Demonstração de uma caixa delimitadora



Fonte: AWS.AMAZON, 2022

A técnica *Non Maximum Suppression* - NMS serve em inúmeras atividades relacionadas à visão computacional. Por ela, são aplicados algoritmos que identificam um objeto ou pessoa, a partir de algumas formas geométricas (como caixas delimitadoras) que tentam se sobrepor a todas as suas partes, selecionando integralmente (SAMBASIVARAO, 2019).

A partir dessa seleção, é possível estabelecer, por um cálculo matemático relacionado à união e interseção dessas figuras, qual seria um ponto médio entre as formas geométricas que alcance integralmente o objeto ou pessoa, conforme a Figura 6, a seguir:



FONTE: TOWARDSDATASCIENCE, 2019

Por esse exemplo, apesar de se tratar da identificação de um único objeto, a técnica aumenta as chances de abranger o veículo todo, selecionando aquelas figuras geométricas com melhor probabilidade de abarcá-lo integralmente.

Data augmentation

Trata-se de um método adotado para tratar imagens disponíveis para o *deep learning*, aumentando o seu número ou sua qualidade, relativo ao reconhecimento delas (GANDHI, 2021).

Então, adotam-se medidas como rotacioná-las, recortar trechos, modificar *zoom* e orientação, entre outros.

Inclusive, há *scripts* prontos que realizam essa atividade automaticamente, suprimindo a ausência de imagens ou mesmo para reforçar uma base de dados já robusta, ampliando a possibilidade de aprendizagem pelo sistema.

Redes Neurais Convolucionais

As redes neurais convolucionais são comumente adotadas em reconhecimento de imagem e seus padrões, segundo o conceito de visão computacional.

O objetivo dessas redes é aprender recursos de ordem superior nos dados por meio de convoluções. Elas são bem adequadas para reconhecimento de objetos com

imagens e consistentemente nas principais competições de classificação de imagens (PATTERSON; GIBSON, 2017).

Assim como redes neurais artificiais, estas redes utilizam a estrutura de camadas, entretanto em seu caso esse número pode crescer bastante. Cada camada possui uma função muito bem estabelecida.

As principais camadas da rede são (PATTERSON; GIBSON, 2017):

- Camada de convolução, responsável por percorrer a imagem mapeando o seu conteúdo. Para isso, é utilizado um filtro que pode ser exemplificado como um pequeno bloco que percorre a imagem, efetuando o mapeamento de sub-blocos;
- Camada de *pooling*, responsável por redimensionar a imagem com base nos dados extraídos da etapa de convolução, reduzindo o seu tamanho;
- Camada totalmente conectada é a responsável por efetuar a classificação das informações obtidas nos passos anteriores, transformando a matriz recebida em uma linha, que contém as informações obtidas.

Observa-se na Figura 7, a seguir, que, conforme a imagem vai passando pelo fluxo das camadas mencionadas acima, o modelo efetua detecção de bordas na primeira camada. Entretanto, na medida em que esse processo se repete, a informação que chegará à última camada é agrupada, de forma que o modelo consiga mapear bordas mais complexas, partindo de uma pequena parte de um objeto, até a sua detecção completa e aprendendo a identificar aos poucos a imagem ou signo conforme a programação que recebe.

Figura 7 - Principais camadas da CNN



Fonte: PATTERSON; GIBSON, 2017

YOLO: *You Only Look Once*

A *You Only Look Once* – YOLO é uma arquitetura que permite a identificação e classificação de objetos, sendo considerado um avanço por conseguir o mesmo nível de detecção que outras ferramentas, mas em tempo substancialmente menor (ALVES, 2020).

Diferente das outras redes neurais convolucionais, a YOLO não utiliza somente camadas densas de conexões entre neurônios, pois adota técnicas de *residual blocks* e *skip connections* (SAHHO, 2018).

Essa arquitetura, por sua vez, realiza a cópia do estado atual da imagem (após alguma convoluções) e a armazena para utilizar esses dados residuais nas camadas mais profundas, pulando as camadas (consoante a técnica *skip connections*). Esse processo se repete ao percorrer as conexões de neurônios, além da realização de três predições, cujos resultados obtidos são reutilizados como métricas de avaliação para aprimorar a capacidade de detecção do modelo. Dessa forma a arquitetura consegue contemplar a correta identificação de objetos grandes, médios e pequenos.

Por se tratar de uma ferramenta de código aberto e livre de licenças de uso, além das vantagens acima mencionadas, vem permitindo o seu uso em larga escala nos mais diversos projetos.

A maior velocidade na obtenção de resultados se relaciona ao fato de o sistema somente necessitar analisar a imagem uma única vez, como seu próprio nome indica.

Ela atua com um sistema de predição e probabilidade, quebrando uma imagem em pedaços menores e tentando enxergar neles quais têm a maior chance de se encaixarem na classe pretendida. Quando o percentual alcança um patamar mínimo (em torno de trinta por cento), esse pedaço de imagem é validado e acrescentado aos demais para delimitar o objeto na imagem (REDMON; FARHADI, 2018).

MÉTRICAS DE IDENTIFICAÇÃO DA APRENDIZAGEM PELO MODELO

Um dos pontos mais importantes quando se desenvolve um modelo de aprendizagem de máquina de visão computacional refere-se ao levantamento de métricas que apontem, objetivamente, o nível de reconhecimento pelo modelo, a partir do que ele

aprendeu. No estágio atual da computação, ainda que se consigam resultados bastante ajustados, seria utópico pensar em uma aplicação com cem por cento de acerto, afinal, como a intenção é que a máquina aprenda tal qual um ser humano e estes cometem erros, logo, é de se esperar que um modelo preditivo também falhe.

Para a avaliação do modelo deste trabalho, serão utilizadas as seguintes métricas (PATTERSON; GIBSON, 2017):

- *Confusion Matrix* é uma tabela que demonstra a classificação para cada classe de um modelo, sendo elas verdadeiro positivo, falso positivo, verdadeiro negativo, falso negativo;
- *Precision* define-se pela divisão entre o verdadeiro positivo e sobre ele mesmo mais o falso positivo, de forma a demonstrar, entre as classificações, qual a porcentagem de acerto;
- Acurácia, que relaciona um resultado experimental (usado como base) do real, expondo a relação entre o que se espera após um estudo e o que a realidade denota;
- *Recall* é definido como divisão entre o verdadeiro positivo, sobre ele mesmo mais o falso negativo, dessa forma demonstrar a porcentagem de previsão do verdadeiro positivo do modelo.

Ademais, faz-se necessário avaliar também a detecção dos objetos que a IA efetuará por meio das seguintes métricas (HUI, 2018):

- *Intersection-over-Union (IoU)* é entendido como a interseção sobre a união da caixa delimitadora detectada e da caixa delimitadora de verdade. Por meio da divisão entre a interseção da área prevista com a área verdadeira, sobre a união da área de ambas, obtêm-se o IoU.
- *Mean average precision (mAP)* é utilizado para analisar a *performance* do modelo ao detectar objetos na imagem, sendo obtido pela média do tamanho das caixas delimitadoras, por classe (HIU, 2018).

APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NA SEGURANÇA PATRIMONIAL

Diante do que se expôs até aqui, a proposta do trabalho relaciona-se à criação de uma inteligência artificial que possa ser treinada a identificar pessoas portando facas ou armas de fogo.

No desenvolvimento, o primeiro passo foi escolher um *framework* de *deep learning/machine learning* para desenvolvimento da IA, optando-se pela ferramenta Pytorch. A escolha deveu-se ao fato de haver razoável suporte para ela (bibliotecas, *datasets* para treinos e exemplos de código, entre outros), relativamente à visão computacional.

Em seguida, buscou-se identificar um modelo de arquitetura para detecção de objetos, sendo escolhido o YOLO na versão 5. O principal motivo para selecioná-lo foi o YOLO ter, como foco, realizar a predição baseada em alta taxa de *frames* por segundo, portanto, realizando o processamento em grande velocidade. Além dessa vantagem, o modelo se destaca pelo equilíbrio entre a precisão e entrega em menor tempo.

Com essas etapas realizadas, decidiu-se pela utilização da técnica de seleção *bounding box*, visando à melhor precisão na identificação de objetos.

Após percorrer esses passos, realizou-se a montagem do *dataset*, utilizando-se tanto algumas bibliotecas disponíveis (SHARMA, 2021 e SASANK, 2018) com o desenvolvimento especificamente para este trabalho. Adotou-se o YouTube para fornecer dados no formato de vídeo, além de imagens e vídeos dos próprios desenvolvedores deste estudo para treino do sistema.


O que se seguiu foi realizar a rotulação manual das imagens e vídeos levantados, através da aplicação *Label Studio*, seguido do pré-processamento das imagens pela ferramenta Roboflow, a partir da seguinte sequência:

- a) redimensionamento da imagem para a dimensão 416x416 pixels;
- b) processamento de *data augmentation*, com o aumento numérico das imagens e vídeos disponíveis e uso de: *flip* (rotação de 180° na imagem) e rotação de 90°, auxiliando o modelo a ser menos sensível à orientação do objeto; *rotation*, rotação da imagem em ângulos menores (1° e 45°), deixando o modelo mais

resistente à movimentação da câmera; *shear*, refere-se à troca de percepção entre as escalas, alternando os seus eixos horizontal e vertical entre si, o que reforçou a resistência do modelo à inclinação e mudança brusca de direção no objeto; *blur*, que consiste em embaçar a imagem, permitindo ao modelo ser remais versátil em relação ao foco da câmera; e *gaussian noise*, utilizado para o modelo generalizar melhor em imagens com ruídos. O aumento na quantidade de dados fez com que os 6.887 arquivos originais saltassem para 42.088, após aplicação do *data augmentation*;

- c) optou-se por utilizar um *batch size* de 36 e 100 épocas, o que totalizou 3.600 lotes. Esse número de 36 refere-se à quantidade de amostras processadas antes que o modelo fosse atualizado. Já as épocas referem-se ao número de passagens completas pelo conjunto de dados de treinamento;
- d) por fim, realizou-se o treinamento da IA a partir dos dados coletados, obtendo-se os resultados na Figura 08, abaixo:

Figura 8 – Resultados obtidos com treino e perda



Fonte: Autores, 2022


Para a análise do *dataset* gerado, este foi dividido e encaminhado para treino (70% do *dataset*), validação (20% do *dataset*) e teste (10% remanescentes). Com o resultado plotado acima, fica evidente que houve uma queda significativa na pontuação da perda durante o treino, na medida em que as épocas avançaram. Já, na etapa de validação, a queda na perda foi ainda maior, apontando resultado satisfatório (sem *overfitting* ou *underfitting*) para essa parametrização.

Grosso modo, *overfitting* ocorre se a IA aprende “demais” sobre os dados, como se tivesse decorado os dados de treino. Um sinal de que isso ocorre é que os dados de treino têm ótimos resultados, mas o mesmo não ocorre em relação à validação. No

underfitting o mau resultado ocorre tanto nos dados de treino quanto nos dados de validação.

A *precision* é o parâmetro de acertos positivos do modelo. Neste caso, a Figura 9 aponta que, com o avanço das épocas, durante o treino, a precisão vai se aprimorando, até atingir o nível de 84%. Disso, observa-se um bom resultado para a aprendizagem da IA. Essa métrica sinaliza que o modelo detém nível aceitável de precisão para realizar a correta detecção de objetos, aproximando-se do resultado almejado.


Figura 9 – Avanço da precisão pelas épocas



Fonte: Autores, 2022

A matriz de confusão (Figura 10) denota o aspecto da confiança, ou seja, o acerto do modelo em enxergar o objeto dentro de uma imagem, conforme seja arma de fogo, faca ou fundo (está presente em todas as imagens). O fundo, que é uma identificação errônea, aparenta ser um falso positivo, pois a IA acaba enxergando nele o objeto, mesmo que este não esteja contido nessa área. Por outro lado, ao identificar o objeto dentro da imagem, ela não confunde uma faca com arma de fogo ou vice-versa.

Figura 10 – Matriz de confusão




Fonte: Autores, 2022

O mAP demonstra a média de acertos da caixa delimitadora, neste caso, nota-se na Figura 11 que a média está dividida em valores menores que 0.5 ou maior ou igual, sendo que estes valores representam o IoU e este é utilizado como limite. Quanto mais perto de 1 o valor, melhor está a capacidade do modelo em definir o correto tamanho das caixas delimitadoras.

Nota-se que conforme as épocas passam, a sua capacidade de precisão avança. Entretanto, a média para o IoU menor se sobrepõe, indicando que o modelo está mais propenso a errar as medidas da caixa delimitadora, tanto para mais quanto para menos, resultando em deformações que nem sempre representam a objeto corretamente.


Figura 11 – mAP



Fonte: Autores, 2022

A Figura 12 mostra algumas falhas identificadas durante um dos dois testes realizados. Relativamente à predição, foram utilizadas 100 imagens distintas. Delas, havia 19 imagens que não possuíam nenhum tipo de arma, mas outros objetos (guarda-chuvas e furadeiras), empunhadas como se fossem armamentos.

Figura 12 – Falhas na identificação



Fonte: Autores, 2022

O modelo demonstrou uma baixa taxa de confiabilidade, acertando apenas 51% das predições, não classificando 25% das imagens, errando em outros 5% e, em 2%, encontrou armamentos onde eles não existiam.

A acurácia encontrada foi de 68%, sendo considerada média para baixa. Como se trata de uma aplicação envolvendo segurança, seria importante o maior número de acertos. Por sua vez, na ocorrência de erros, acaba demonstrando a necessidade de uma presença humana que confirme a identificação da IA ou o aprimoramento desta.

No segundo teste foram considerados dois vídeos distintos, sendo um deles um assalto gravado por uma câmera de vídeo monitoramento e o outro de uma pessoa segurando objeto distinto (furadeira e guarda-chuva).


No vídeo do assalto, é possível notar a recorrência constante da predição equivocada no background do vídeo. Mesmo assim, também é possível notar a correta detecção da arma no início de sua aparição, mas, no decorrer das variações nas posturas das pessoas, em dados momentos, o modelo deixa de identificar a pistola.

No segundo vídeo, percebe-se que o modelo associa outros objetos (furadeira e guarda-chuva) a arma ou faca, conforme a posição da mão ao erguer cada objeto. Tal análise aponta uma tendência de a IA se basear na forma de empunhadura do item para considerá-lo uma arma/faca, desconsiderando o formato do objeto em si, apesar de que este deveria ser o alicerce do modelo para a predição. Isso se deve ao modo como a técnica de *bouding box* foi implementada na hora de realizar o tagueamento das imagens de teste.

Em relação à correta identificação dos objetos pela IA, exemplifica-se:

No compilado de imagens a seguir (Figura 13), observa-se como foi feita a correta identificação pela IA, que percebeu cada tipo de arma portada (faca ou arma de fogo), o que restou detalhado em cada foto. Além disso, no campo do *bouding box* de cada imagem, também há o número que identifica o percentual de confiança na identificação do objeto dentro de toda a figura.

Figura 13 – Exemplos de identificações corretas obtidas





Fonte: Autores, 2022

Comparando-se os erros e acertos nas predições, percebe-se maior êxito na identificação de objetos em fotos do que em vídeo.

Além disso, a IA é capaz de realizar a correta detecção dos objetos alvos (arma e facas), entretanto ainda não consegue garantir uma taxa alta de fidelidade do dado, denotando que ainda necessita de aperfeiçoamento.

Dito isso, conclui-se pelo atendimento do estudo proposto, mediante demonstração prática do resultado alcançado, pois foi possível desenvolver um programa de inteligência artificial que aprendesse a reconhecer pessoas portando arma de fogo ou faca, com margem de erros média para baixa.

Por sua vez, dentre as métricas abordadas, a *precision* foi a que apresentou melhor resultado, pois apontou que a precisão do sistema foi se aprimorando com o avanço das épocas.

CONCLUSÃO

Ao longo deste trabalho, após seleção de dois comportamentos vedados na legislação, relativamente ao porte de facas e armas de fogo, evidenciou-se que é possível ensinar uma inteligência artificial a reconhecer essa posse, de forma a automatizar a identificação desse comportamento, de maneira que se conclui pelo alcance do objetivo geral desta pesquisa.

Apesar de a métrica de acurácia não ter apontado um percentual bom, a *precision* denotou que, na medida em que se for apresentando imagens à IA, esta conseguirá aprimorar seu conhecimento na identificação dos objetos em questão. Então, ainda que se pudesse concluir pela falibilidade do modelo apresentado, a princípio, acredita-se que foi apresentado um modelo que demandaria maior base de dados, especialmente em ambientes reais, para aprimoramento de sua aprendizagem e melhora dos resultados.

Portanto, o que se apresentou neste trabalho é um protótipo, que evidencia ser possível confirmar a premissa originalmente proposta, mas que necessita de aprimoramentos tanto visando melhor resultado nas métricas utilizadas, como para futuro oferecimento ao mercado consumidor.

Uma das medidas possíveis a ser implementada é o acionamento de um alarme ou disparo de mensagens de alerta, quando o sistema perceber estar diante da situação apontada. Outra possibilidade refere-se à predição de pessoas que portem armas, mas ainda não as expuseram, o que exigiria a adição de um *dataset* específico, incluindo essa nova hipótese.

Esses são exemplos de tantas outras implementações possíveis, na medida em que, a presente área de estudos, ainda é bastante incipiente, tendo ampla possibilidade de crescimento e demanda.

REFERÊNCIAS

ADALOGLOU, Nikolas. **Intuitive Explanation of Skip Connections in Deep Learning** . Portal TheAISummer, 2020. Disponível em: <<https://theaisummer.com/skip-connections/>>. Acesso em: 25 ago 2022.

ALECRIM, Emerson. **Machine learning: o que é e por que é tão importante**. Portal tecnoblog, 2018. Disponível em: <<https://tecnoblog.net/responde/machine-learning-ia-o-que-e/>>. Acesso em 20 abr. 2022.

ALVES, Gabriel. **Deteção de Objetos com YOLO – Uma abordagem moderna** . Portal IAExpert, 2020. Disponível em: <<https://iaexpert.academy/2020/10/13/deteccao-de-objetos-com-yolo-uma-abordagem-moderna/>>. Acesso em: 02 set 2022.

AMAZON. **Exibir caixas delimitadoras**. Portal Amazon, 2022. Disponível em: <https://docs.aws.amazon.com/pt_br/rekognition/latest/dg/images-displaying-bounding-boxes.html>. Acesso em: 23 out. 2022.

BATISTA, Vera. **Apenas 44% dos homicídios são esclarecidos no Brasil, diz Instituto Sou da Paz**. Portal Correio Brasiliense, 2021. Disponível em:

<<https://www.correiobraziliense.com.br/brasil/2021/10/4955098- apenas-44-dos-homicidios-sao-esclarecidos-no-brasil-diz-instituto-sou-da-paz.html>>. Acesso em 29 out. 2022.

BRASIL. **Decreto-lei nº 3.688, de 03 de Outubro de 1941.** Lei das Contravenções Penais. Disponível em: <http://www.planalto.gov.br/ccivil_03/decreto-lei/del3688.htm>. Acesso em: 01 out. 2022.

BRASIL. **Decreto-lei nº 3.689, de 03 de Outubro de 1941.** Código de Processo Penal. Disponível em: <http://www.planalto.gov.br/ccivil_03/decreto-lei/del3689.htm>. Acesso em: 28 abr. 2022.

BRASIL. **Lei 10.826, de 22 de Dezembro de 2003.** Estatuto do Desarmamento. Disponível em: <http://www.planalto.gov.br/ccivil_03/leis/2003/L10.826compilado.htm>. Acesso em: 01 out. 2022.

CARVALHO, André Ponce de L. F. de. **Redes Neurais Artificiais.** Portal ICMC USP. Disponível em: <<https://sites.icmc.usp.br/andre/research/neural/>>. São Paulo, 2009. Acesso em 24 abr. 2022.

DASCI, Ari. **OD-Weapon Detection.** Portal GitHub, 2022. Disponível em: <<https://github.com/ari-dasci/OD-WeaponDetection>>. Acesso em: 10 out. 2022.

FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA. **Anuário Brasileiro de Segurança Pública 2022 - Os crimes patrimoniais no Brasil: entre novas e velhas dinâmicas.** Portal Fórum Segurança, 2022. Disponível em: <<https://forumseguranca.org.br/wp-content/uploads/2022/07/07-anuario-2022-os-crimes-patrimoniais-no-brasil-entre-novas-e-velhas-dinamicas.pdf>>. Acesso em 30 out. 2022.

GANDHI, Arun. **Data Augmentation | How to use Deep Learning when you have Limited Data.** Portal NanoNets, 2021. Disponível em: <<https://nanonets.com/blog/data-augmentation-how-to-use-deep-learning-when-you-have-limited-data-part-2/>>. Acesso em: 02 set 2022.

HIU, JONATHAN. **mAP (mean Average Precision) for object Detection.** Portal Medium, 2018. Disponível em: <<https://jonathan-hui.medium.com/map-mean-average-precision-for-object-detection-45c121a31173>>. Acesso 10 jun 2022.

IBM. **Bounding Boxes.** Portal IBM, 2021. Disponível em: <<https://www.ibm.com/docs/en/informix-servers/12.10?topic=structure-bounding-boxes>>. Acesso em: 03 nov. 2022.

IBM. **Recurrent neural networks.** Portal IBM, 2020. Disponível em: <<https://www.ibm.com/cloud/learn/recurrent-neural-networks>>. Acesso em: 14 jun. 2022.

IBM. **Redes neurais.** Portal IBM, 2020. Disponível em: <<https://www.ibm.com/br-pt/cloud/learn/neural-networks>>. Acesso em: 22 abr. 2022.

INTEL. **O que é visão computacional?.** Portal Intel. Disponível em: <<https://www.intel.com.br/content/www/br/pt/internet-of-things/computer-vision/overview.html#:~:text=A%20vis%C3%A3o%20computacional%20utiliza%20aprendizagem,e%20at%C3%A9%20mesmo%20rastrear%20movimentos>>. Acesso em: 23 abr. 2022.

JOHNSON CONTROLS. **ADT dá dicas de segurança para quem tem comércio.** Portal Blog ADT, 2018. Disponível em: <<https://blog.adt.com.br/adt-da-dicas-de-seguranca-para-quem-tem-comercio/>>. Acesso em 25 out. 2022.

LUCENA, David. **Brasil é o 22º país do mundo com maior índice de crime organizado.** Portal O Tempo, 2021. Disponível em: <<https://www.otempo.com.br/brasil/brasil-e-o-22-pais-do-mundo-com-maior-indice-de-crime-organizado-1.2562573>>. Acesso em 29 out. 2022.

MOURA, Shayne de Oliveira. **Uma abordagem para a escolha do melhor Método de Seleção de Instancias usando meta-aprendizagem.** Dissertação (Mestrado em Ciência da Computação) – Pós-Graduação em Ciência da Computação, Universidade Federal de Pernambuco, Recife, 2015. Disponível em: <https://repositorio.ufpe.br/bitstream/123456789/16311/1/Shayane_FINAL.pdf>. Acesso em: 25 abr. 2022.

NEUMANN, Nélvio Alberto. **Nota de instrução nº 079/BM/EMBM/2001.** Porto Alegre, 2001.

PATTERSON, Josh; GIBSON, Adam. **Deep Learning: A practitioner's approach.** O'Reilly Media, inc. 2017.

REDMON, Joseph; FARHADI, Ali. **YOLOv3: An Incremental Improvement.** Portal Arxiv, 2018. Disponível em: <<https://arxiv.org/pdf/1804.02767v1.pdf>>. Acesso em 10 ou. 2022.

RUSSEL, Stuart. **Inteligência artificial.** Rio de Janeiro: Elsevier, 2013.

SAMBASIVARAO, K. **Non-maximum Suppression (NMS): A technique to filter the predictions of object detectors.** Portal Towardsdatascience, 2019. Disponível em: <<https://towardsdatascience.com/non-maximum-suppression-nms-93ce178e177c>>. Acesso em: 30 ago 2022.

SAHHO, Sabyasachi. **Residual blocks – Building blocks of ResNet.** Portal Towardsdatascience, 2018. Disponível em: <<https://towardsdatascience.com/residual-blocks-building-blocks-of-resnet-fd90ca15d6ec>>. Acesso em: 30 ago 2022.

SASANK, Sai. **Guns Object Detection.** Portal Kaggle, 2018. Disponível em: <<https://www.kaggle.com/datasets/issaisasank/guns-object-detection>>. Acesso em: 15 out. 2022.

SHARMA, Ankan. **Weapon Detection Dataset.** Portal Kaggle, 2021. Disponível em: <<https://www.kaggle.com/datasets/ankan1998/weapon-detection-dataset>>. Acesso em: 19 set. 2022.

SZYMIK, Brett. **Neuron Anatomy.** Portal ASU - Ask A Biologist. Disponível em: <<https://askabiologist.asu.edu/neuron-anatomy>>. Arizona, 2011. Acesso em 20 maio 2022.

VICERI. **Métricas de performance e funções de perda para Machine Learning.** Portal Viceri, 2020. Disponível em: <<https://viceri.com.br/insights/metricas-de-performance-e-funcoes-de-perda-para-machine-learning/>>. Acesso em: 02 maio 2022.

ZHANG, Aston *et al.* **Dive into Deep Learning.** Portal d2l. Disponível em: <<https://d2l.ai/d2l-en.pdf>>. Acesso em 29 abr. 2022.